전기정보공학과

캡스톤디자인 전시회

심전도 잡음 제거 기법의 정량적 비교 연구

조원 이름 : (입력)

담당교수 : (입력)

작품 개요
자체 제작한 ECG 취득 장치 (AD8232, Arduino Uno) 의 잔류 잡음을 줄이는 후처리 기법을 정량적으로 비교하였다. 고전 필터 · 웨이블릿 임계값 처리 · 칼만 필터 · 딥러닝을 동일한 입력 · 공통 전처리 · 평가 지표로, 합성 ECG 와 MIT-BIH 실측 기록에서 평가하였다. 본 시스템은 연구용 신호처리 시스템이며 임상 진단 용도가 아니다.

작품 내용

잡음 종류와 입력 SNR 에 따라 적합한 기법이 달라지는지를 다섯 단계로 분석하였다. 평가 체계는 기법 구현보다 먼저 확정하였다.

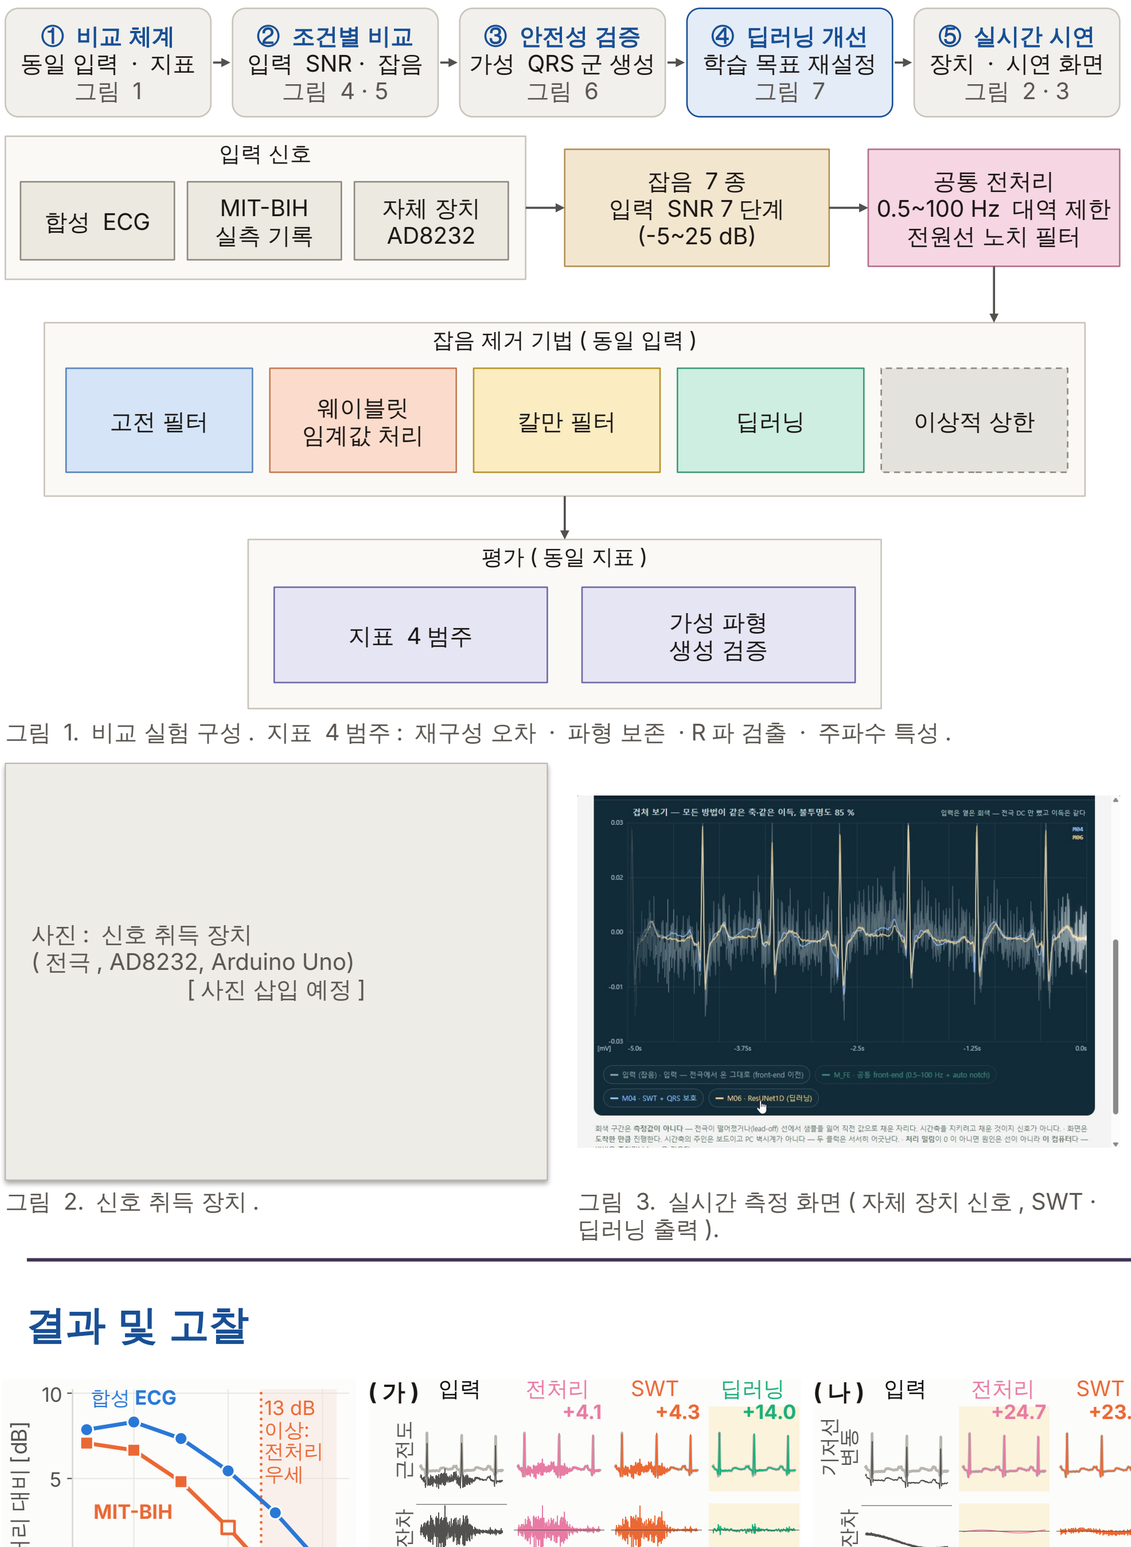


그림 1. 비교 실험 구성. 지표 4 범주 : 재구성 오차 · 파형 보존 · R 파 검출 · 주파수 특성.

그림 2. 신호 취득 장치.

그림 3. 실시간 측정 화면 (자체 장치 신호 , SWT · 딥러닝 출력).

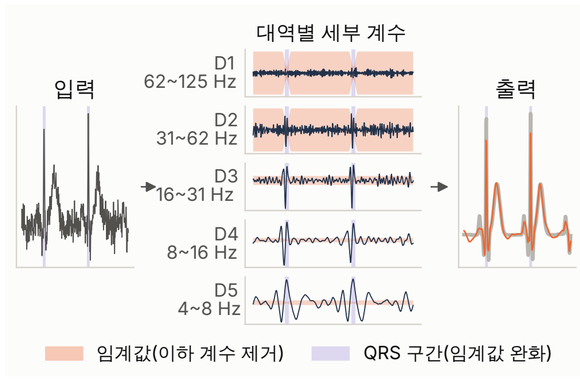
이론적 배경

① 정상 웨이블릿 변환 (SWT) 적응 임계값 처리

입력을 다섯 개 주파수 대역의 세부 계수로 분해하고, 대역마다 다른 임계값을 적용한 뒤 다시 합성한다.

$$\lambda_j = k_j\,\sigma\,\sqrt{2\ln N}\;\left(1-(1-\rho)\,g(t)\right)$$

k: 대역별 임계값 배율 , σ: 잡음 표준편차 , g(t): QRS 구간의 임계값 완화 함수 .
장점 무잡음 입력의 왜곡이 가장 작다 (출력 SNR 40.1 dB).
한계 기저선 변동 · 임펄스 잡음은 제거하지 못한다.

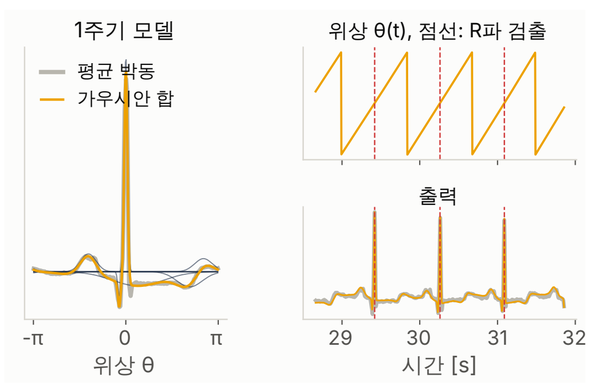


② 확장 칼만 필터 (McSharry 모델)

ECG 한 주기를 심장 위상 θ 위 가우시안 함수 (P · Q · R · S · T 파) 의 합으로 모델링한다.

$$\dot{\theta}=\omega,\qquad \dot{z}=-\sum_i \frac{\alpha_i\,\omega}{b_i^{2}}\,\Delta\theta_i \exp\!\left(-\frac{\Delta\theta_i^{2}}{2\,b_i^{2}}\right)$$

위상은 검출된 R 파마다 0 으로 재설정되고, 칼만 필터 (순방향 추정 뒤 역방향 평활) 로 상태 [θ, z] 를 추정한다.
장점 모델과 맞는 합성 ECG 에서 SNR 개선량이 크다 (+16.2 dB).
한계 R 파 오검출 위치에 가성 QRS 군을 만든다.



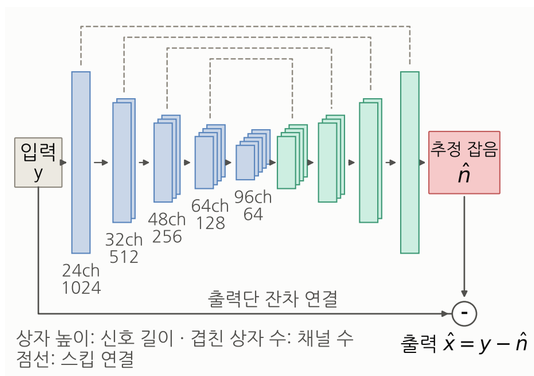
③ 잔차 학습 1D U-Net

인코더가 신호 길이를 반씩 줄이며 채널을 늘리고, 디코더가 스킵 연결로 복원한 추정 잡음을 입력에서 뺀다.

$$\hat{x}=y-f_\theta(y)$$

$$\mathcal{L}=\mathcal{L}_{\mathrm{MSE}}+0.5\,\mathcal{L}_{\mathrm{MAE}}+0.3\,\mathcal{L}_{\mathrm{diff}}+\lambda\,\mathcal{L}_{\mathrm{clean}}$$

장점 13 dB 미만 · 임펄스 잡음에서 우수하고, 가성 파형 생성 에너지가 고전 기법보다 낮다.
한계 무잡음 입력도 변형한다 (출력 SNR 22.2 dB, 무잡음 입력 보존 손실 적용 시 37.4 dB).



결과 및 고찰

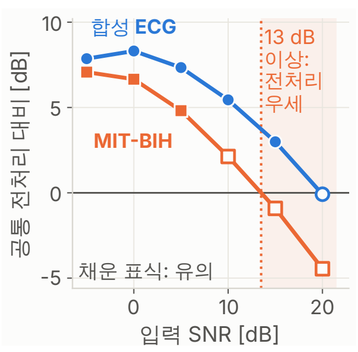


그림 4. 공통 전처리 대비 딥러닝의 SNR 개선량.

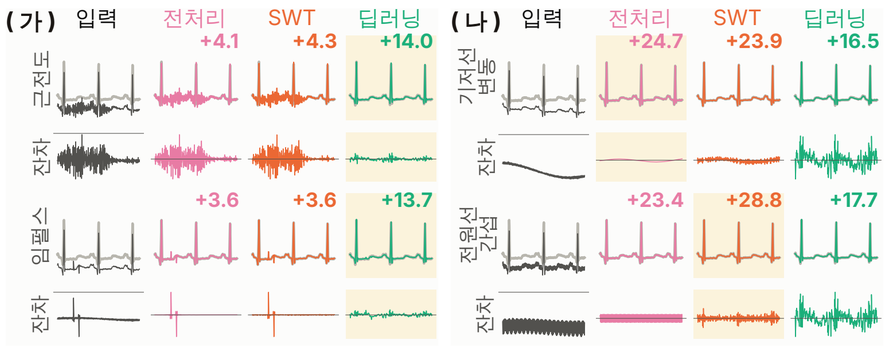


그림 5. 잡음 종류별 우세 기법 (MIT-BIH, 입력 SNR +10 dB). 숫자 = 평균 SNR 개선량 [dB], 음영 = 최고, 아래 행 = 잔차.

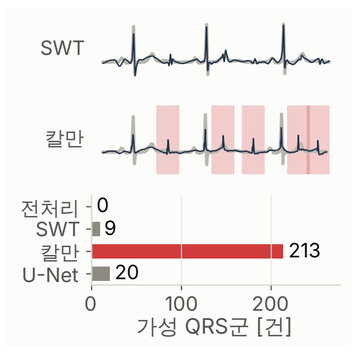


그림 6. 기법별 가성 QRS 군 (MIT-BIH).

고찰

연구의 의의

- 기법의 우열은 잡음 종류 · 입력 SNR · 평가 데이터를 지정해야 정의된다. 합성 ECG 에서 전 구간에 걸쳐 나타난 딥러닝의 우위는 MIT-BIH 에서 재현되지 않았고, 약 13 dB 이상에서는 공통 전처리 단독이 더 높았다 (그림 4).
- 칼만 필터의 가성 QRS 군은 오차 에너지로는 드러나지 않았고, 박동 유사도로 측정하자 SWT 의 약 24 배였다 (그림 6). 지표를 여러 층으로 둔 근거이다.
- 시드 대응 비교와 Holm 보정으로 검정한 결과, 성능 향상은 학습 목표를 바꾼 시도 (무잡음 입력 보존 손실 , SNR 조건화) 에서만 확인되었다 (그림 7).

한계와 원인

- 고 SNR 구간의 열세는 단일 모델이 전 입력 SNR 대역을 학습하며 절충한 결과로 해석된다. 15~20 dB 전용 모델은 +4.4 dB 높았으나 시드 3 개의 결과이다 (p_{Holm} = 0.33).
무잡음 입력 보존 손실과 SNR 조건화의 효과는 가산되지 않았다 (+0.2 dB, p = 0.14).
- SNR 조건화에는 실제 입력 SNR 을 사용하였다. 실측 신호에는 추정 SNR 이 필요하며, 조건 SNR 을 8 dB 낮게 입력하면 -1.0 dB, 높게 입력하면 -0.1 dB 변하였다.
- 평가는 공개 데이터 두 종의 22 개 기록에 한정되며, MIT-BIH 기준 신호가 0.5~100 Hz 대역 제한 신호이므로 결론도 이 대역에 한정된다.

발전 방향

- 자체 장치의 신호 · 잡음을 수집하여 입력 SNR 구간을 측정하고, 추정 SNR 조건화와 장치 간 도메인 적응을 검증한다.
- 무잡음 입력 보존 손실을 사전 지정하여 주 실험을 재수행하고, 딥러닝 비교는 시드 10 개로 재검정한다.



그림 7. 딥러닝 개선 과정. 기준 모델 대비 SNR 개선량 변화 (동일 평가 집합, 동일 시드 대응 t- 검정, 시드 n = 3~6, 비교 25 개 Holm 보정).

SEOULTECH 서울과학기술대학교

정보통신대학