연구 개요

연구 목표

자체 제작한 심전도 (ECG) 취득 장치 (AD8232, Arduino Uno) 의 잔류 잡음을 파형을 보존하면서 줄이는 디지털 후처리 기법을 규명한다 .

분석 항목

① 잡음 종류와 입력 SNR 에 따른 적합 기법의 변화
② 입력에 없는 파형 (가성 QRS 군) 의 생성
③ 실시간 처리에서의 파형 왜곡

비교 대상

고전 필터 · 웨이블릿 임계값 처리 · 칼만 필터 · 딥러닝

데이터

합성 ECG(McSharry 모델), MIT-BIH 부정맥 데이터베이스와 NSTDB 실측 잡음

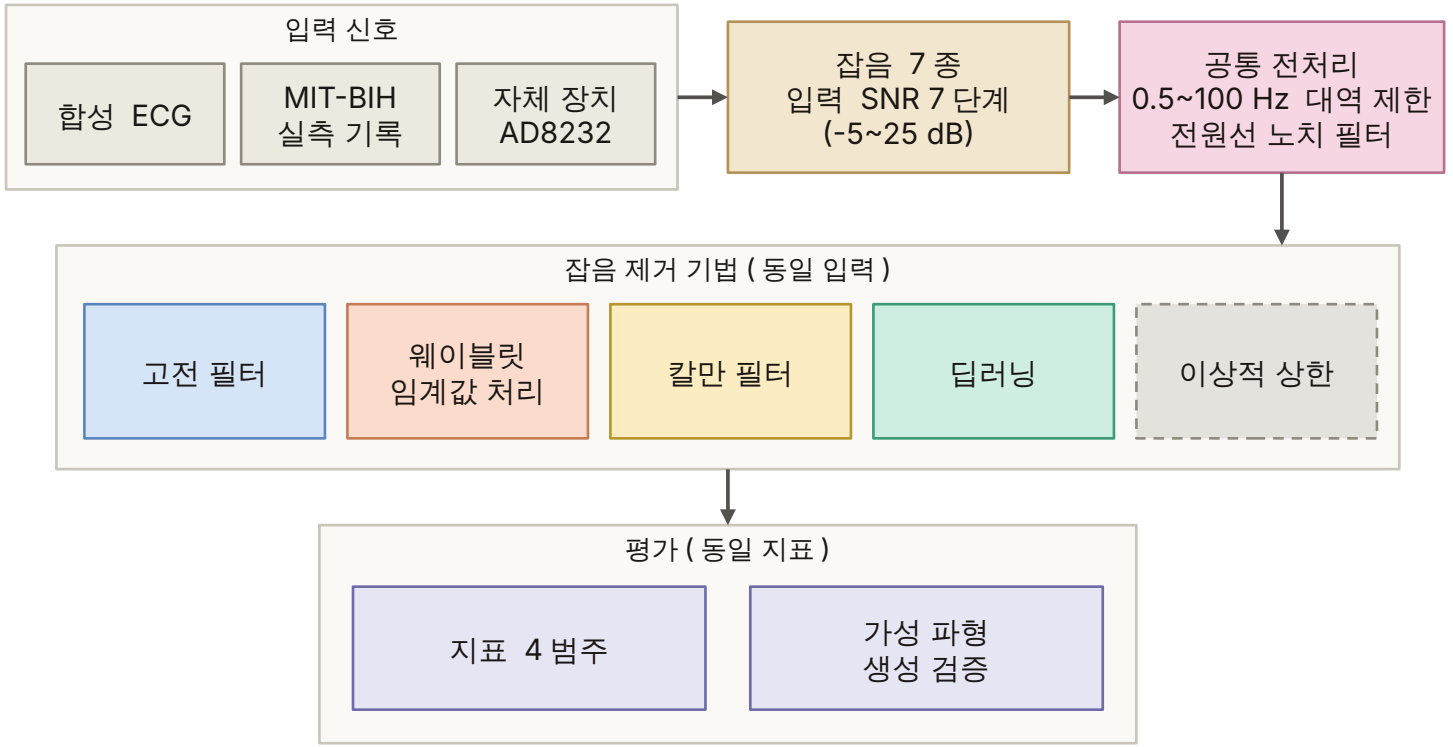


그림 1. 비교 실험 구성 . 평가 지표 4 범주 : 재구성 오차 · 파형 보존 · R 파 검출 · 주파수 특성 .

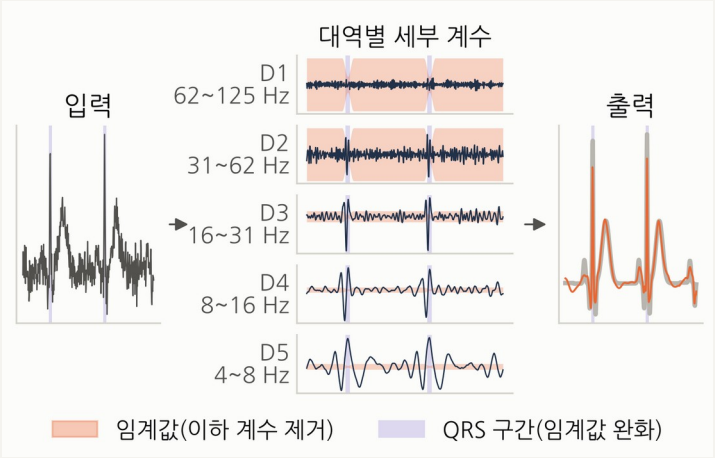
① 비교 체계 — 동일 입력 · 지표 — 1 쪽 → ② 조건별 비교 — 입력 SNR · 잡음 종류 — 3 쪽 → ③ 안전성 검증 — 가성 파형 · 왜곡 — 4 쪽 → ④ 딥러닝 개선 — 학습 목표 재설정 — 5 쪽 → ⑤ 시연 — 전시 화면 · 실시간 측정 — 6~7 쪽

이론적 배경

① 정상 웨이블릿 변환 (SWT) 적응 임계값 처리

입력을 다섯 주파수 대역의 계수로 분해하고 , 대역별 임계값을 적용한 뒤 재합성한다 .

$$\lambda_j = k_j\,\sigma\,\sqrt{2\ln N}\;\left(1-(1-\rho)\,g(t)\right)$$

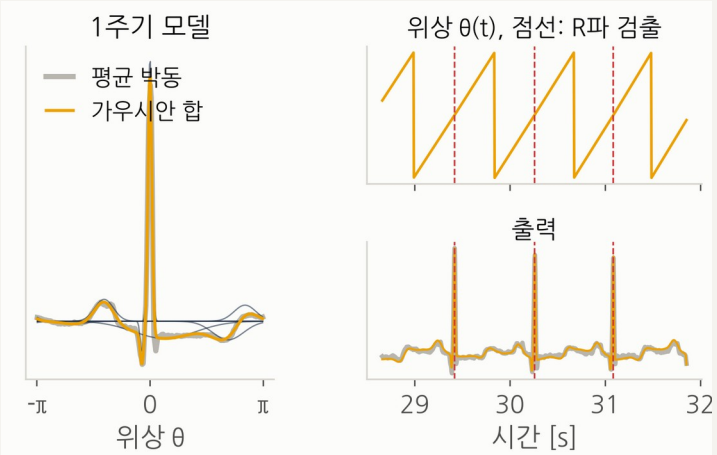


장점 무잡음 입력의 왜곡이 가장 작다 (출력 SNR 40.1 dB).
한계 기저선 변동 · 임펄스 잡음의 제거 성능이 낮다 .

② 확장 칼만 필터 (McSharry 모델)

심전도 한 주기를 심장 위상 θ 위 가우시안 함수의 합으로 모델링하고 상태 [θ, z] 를 추정한다 .

$$\dot{\theta} = \omega, \qquad \dot{z} = -\sum_i \frac{\alpha_i\,\omega}{b_i^2}\,\Delta\theta_i \exp\!\left(-\frac{\Delta\theta_i^2}{2\,b_i^2}\right)$$

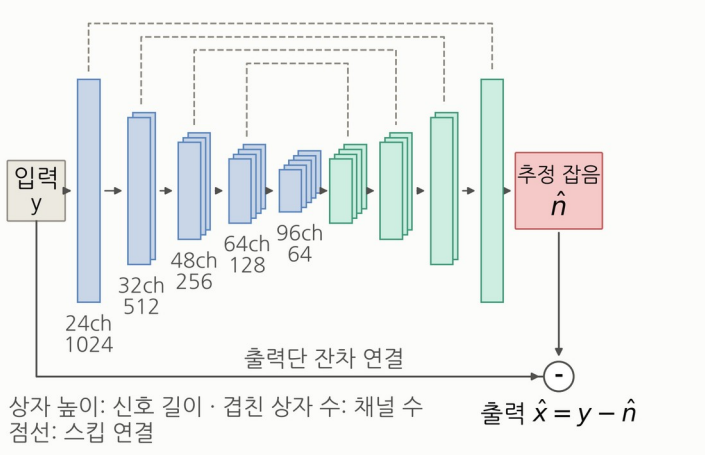


장점 모델과 일치하는 합성 ECG 에서 SNR 개선량이 크다 (+16.2 dB).
한계 R 파 오검출 위치에 가성 QRS 군을 생성한다 .

③ 잔차 학습 1D U-Net

인코더 · 디코더와 스킵 연결로 잡음을 추정하고 , 입력에서 추정 잡음을 감산한다 .

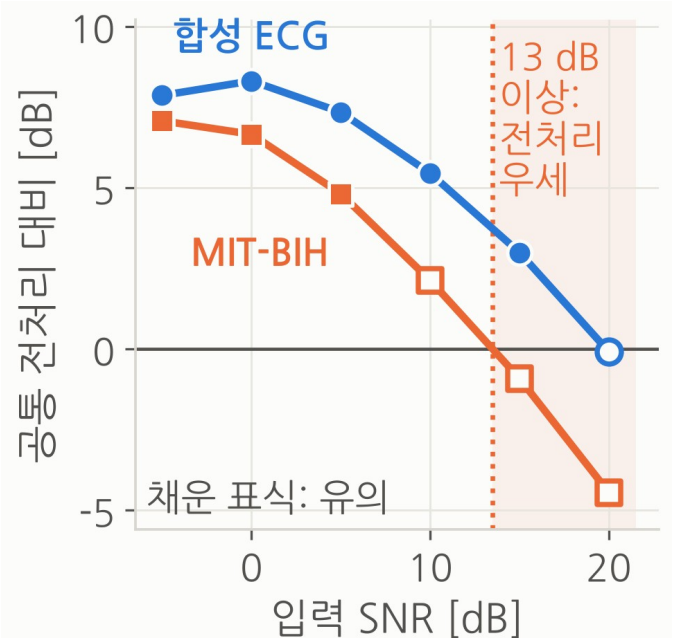
$$\hat{x} = y - f_\theta(y)$$



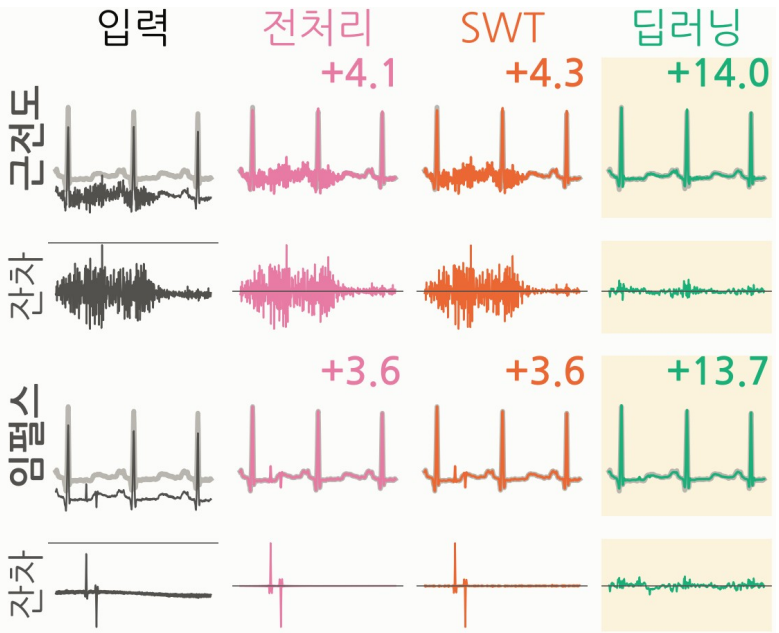
장점 입력 SNR 13 dB 미만 · 임펄스 잡음에서 우수하다 .
한계 무잡음 입력도 변형한다 (출력 SNR 22.2 dB, 보존 손실 적용 시 37.4 dB).

결과 ① 잡음 종류와 입력 SNR 에 따른 우세 기법

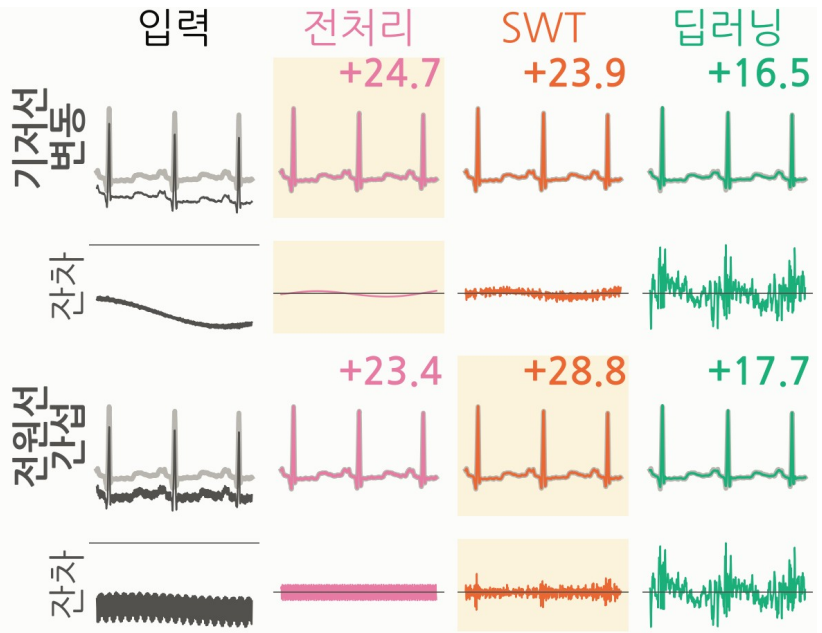
(가)



(나)



(다)



(가) 공통 전처리 대비 딥러닝의 SNR 개선량 (입력 SNR 별).

(나) 딥러닝 우세 잡음, (다) 고전 처리 우세 잡음. MIT-BIH, 입력 SNR +10 dB, 44 개 구간 평균 SNR 개선량 [dB], 음영 = 최고, 아래 행 = 잔차.

- MIT-BIH 에서 딥러닝의 우위는 입력 SNR 약 13 dB 미만에 한정되었고, 그 이상에서는 공통 전처리 단독이 우세하였다 (가).
- 근전도 · 임펄스 잡음에서는 딥러닝이 SWT 보다 각각 9.7 dB, 10.1 dB 높았다 (나).
- 기저선 변동은 공통 전처리 단독, 전원선 간섭은 SWT 가 가장 높았고, 딥러닝은 두 잡음에서 잔차를 남겼다 (다).

결과 ② 가성 QRS 군 생성과 실시간 처리의 파형 왜곡

칼만 필터의 가성 QRS 군 (MIT-BIH)

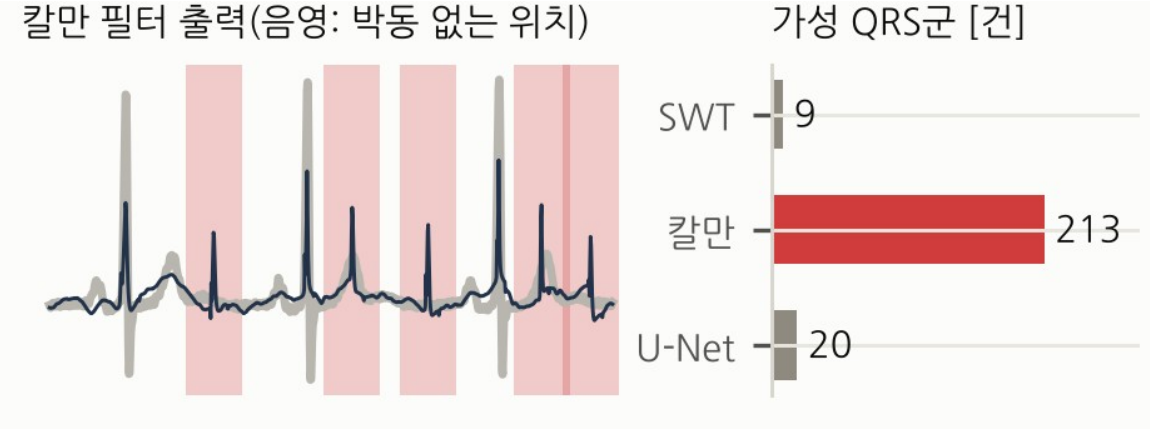


그림 2. 칼만 필터 출력 (음영 : 박동이 없는 위치) 과 기법별 가성 QRS 군 수 .

- 칼만 필터는 R 파 오검출 위치에 박동 형태의 파형을 출력하였다 . 가성 QRS 군은 213 건으로 SWT 대비 약 24 배 , 딥러닝 대비 약 11 배였다 (입력 SNR −5 · 0 dB).
- 오차 에너지 지표에서는 드러나지 않았으며 , 위양성 검출 가운데 평균 박동과의 상관계수가 0.8 을 넘는 경우로 판정하였다 .

실시간 공통 전처리의 QRS 직후 왜곡 (MIT-BIH)

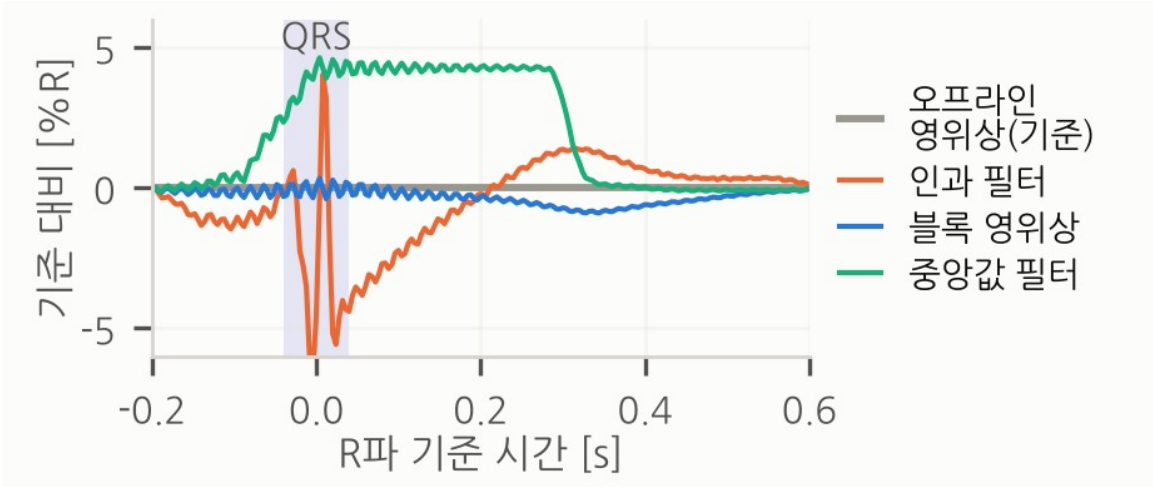


그림 3. 공통 전처리 방식별 평균 박동의 편차 (기록 100, R 파 진폭 대비 %). 편차는 R 파 이후 40~600 ms 구간에서 측정 .

- 인과 고역통과 필터는 QRS 직후 구간에서 오프라인 영위상 필터 대비 최대 3.8 %R 의 편차를 보였다 .
- 0.5 초 블록 영위상 필터의 편차는 최대 0.9 %R 로 오프라인 처리와 거의 같았다 . 대신 약 0.5 초의 처리 지연이 추가된다 .

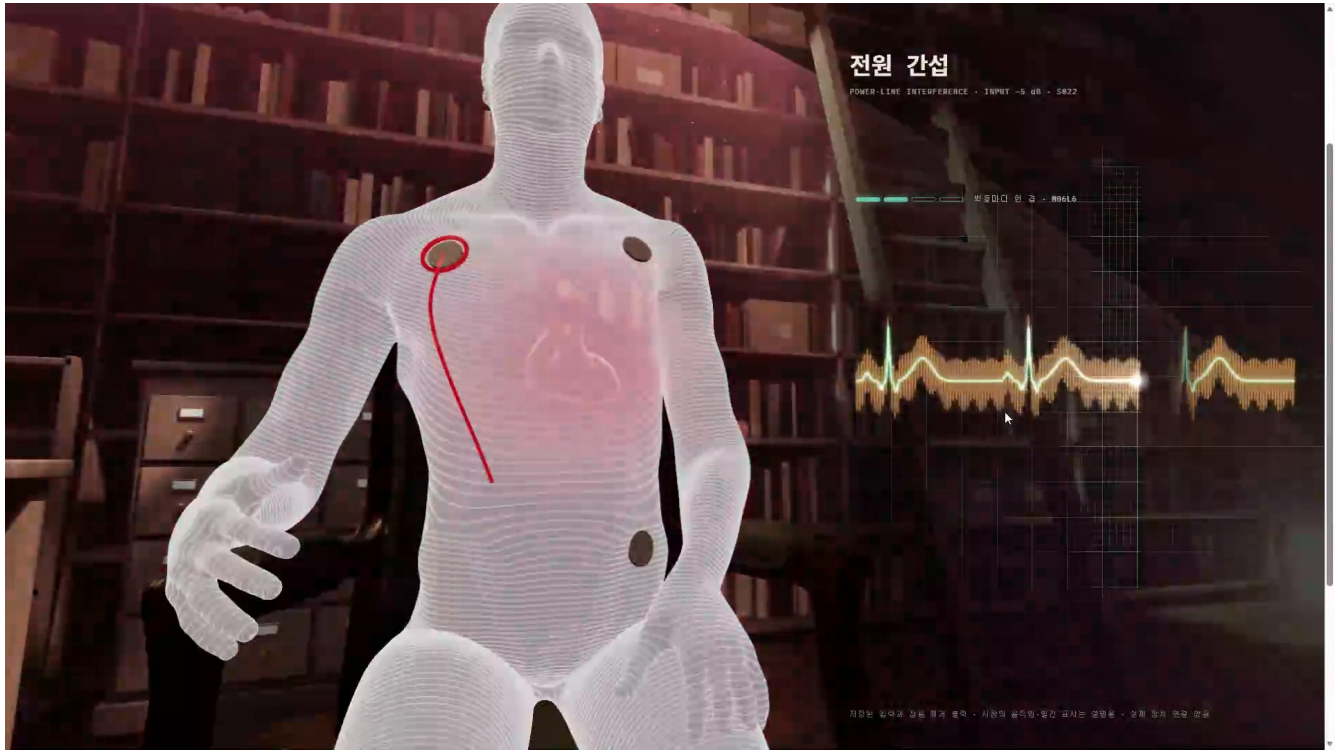
결과 ③ 딥러닝 개선 과정



그림 4. 딥러닝 개선 과정 . 기준 모델 대비 SNR 개선량 변화 (동일 평가 집합 , 동일 시드 대응 t- 검정 , 시드 n = 3~6, 비교 25 개 Holm 보정).

- 유의한 성능 향상은 학습 목표를 바꾼 두 시도 (무잡음 입력 보존 손실 , SNR 조건화) 에서만 확인되었다 .
- 구조 변경 가운데 SWT 직렬 결합은 성능 저하를 보였다 (p_{Holm} = 0.04).
- 고 SNR 구간의 열세는 단일 모델이 전 입력 SNR 대역을 학습하며 절충한 결과로 해석된다 .
- 15~20 dB 전용 모델은 기준 모델보다 +4.4 dB 높았으나 유의하지 않았다 (p_{Holm} = 0.33, 시드 3 개).

시연 ① 전시 화면



영상 1. 도입부의 전원 간섭 장면 (14 s). 전원선 주변의 전기장이 신체를 거쳐 심전도 잡음으로 나타나는 과정 .



그림 5. 도입부의 잡음 원인 세 장면 : 전원 간섭 · 기저선 변동 · 근전도 .

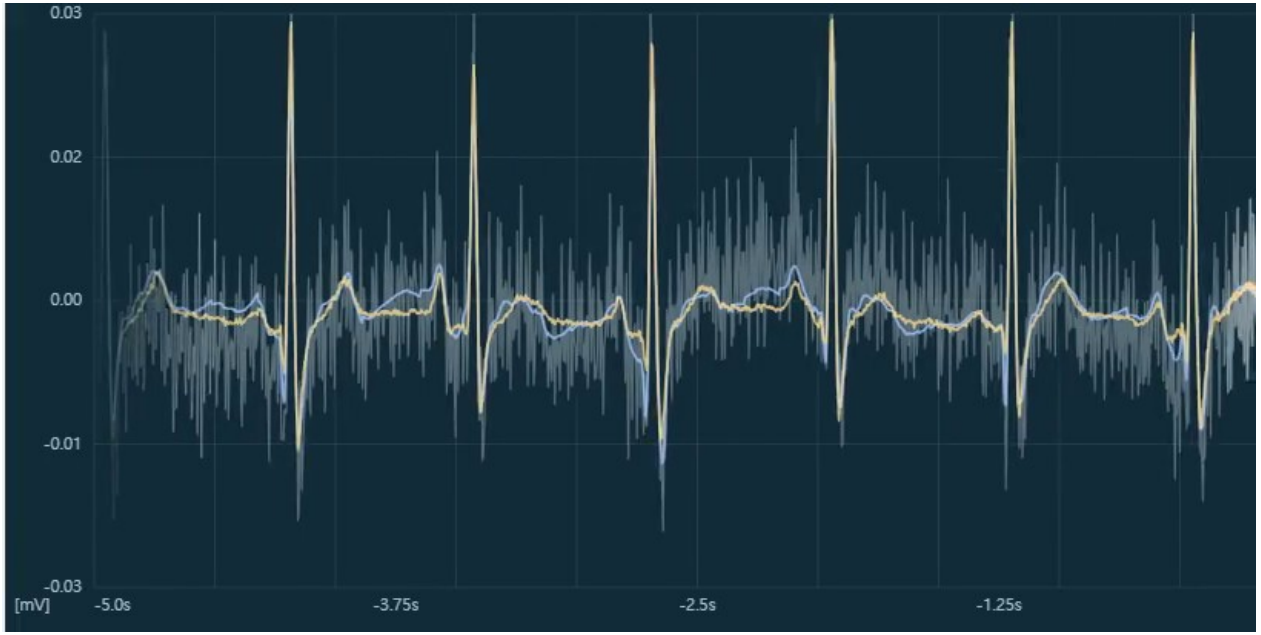


그림 6. 동일 박동의 입력 (잡음) 과 처리 결과의 중첩 표시 .



그림 7. 실험실 화면 : 입력과 기법별 출력의 동일 축 비교 .

시연 ② 실시간 측정



영상 2. 자체 장치 신호의 실시간 처리 (10 s, 그래프 영역). 입력 (회색) 위에 SWT(파랑) 와 잔차 학습 U-Net(노랑) 출력을 중첩 표시 .

측정 경로

전극 · AD8232 → Arduino Uno 500 Hz 표본화 → PC 처리 250 Hz · 기법 → 화면 중첩 표시

측정 상태 (경과 231.8 s)

644 ms	0	0.53
처리 지연	**샘플 손실**	**실시간 계수**
미리보기 548 ms + 기법 96 ms	전극 분리 0 재동기화 0	처리 시간 ÷ 신호 시간 (1 미만 : 실시간 처리)

실측 신호에는 기준 신호가 없으므로 이 화면은 파형과 처리 상태만 표시하며 , 기법 간 정량 비교는 3~5 쪽의 결과로 제시한다 .

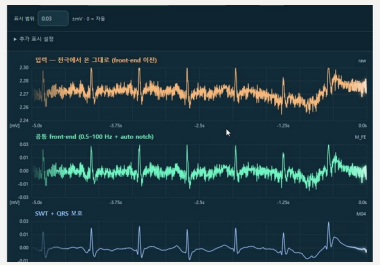
시연 화면의 개발 단계

① 벤치마크 화면
기록 신호 (MIT-BIH)에 기준 신호를 겹쳐 기법별 출력을 비교



→

② 실시간 측정 화면
자체 장치를 연결하여 실시간 처리 경로를 검증 (2026-10-16)



→

③ 최종 GUI
벤치마크 비교와 실시간 측정을 한 프로그램의 탭으로 통합 , 실시간 측정 탭은 ②와 동일